

گزارش حل مسئله «سنجش کیفیت»

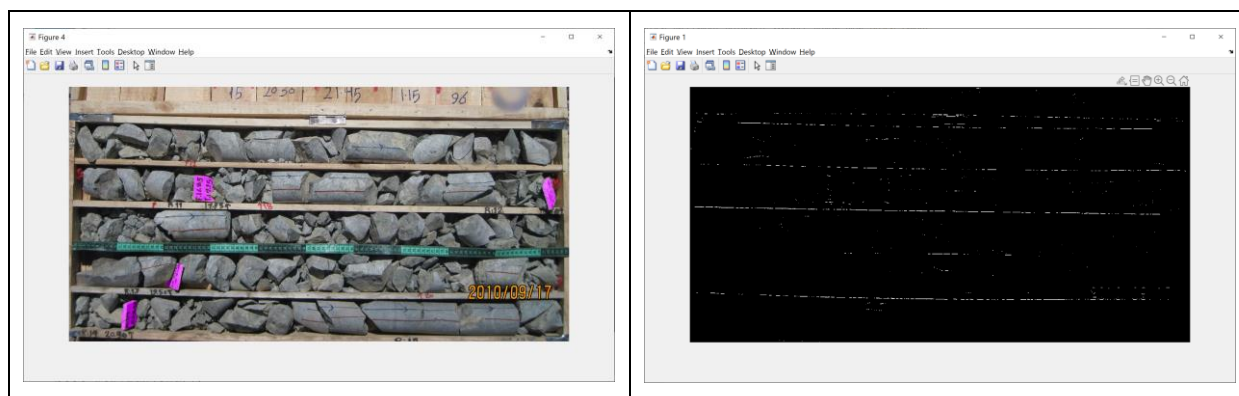
مجید فرزانه – نام کاربری: Majid Farzaneh

مقدمه

در این گزارش، ابتدا چگونگی حل مسئله سنجش کیفیت ارائه شده و پس از آن به سوالات ۱ و ۲ در مسئله گزارش نویسی پاسخ مناسب داده می شود. برای حل مسئله سنجش کیفیت از تکنیک های متنوعی استفاده شده است. به منظور جداسازی ناحیه ی موردعلاقه (ROI^۱)، یعنی ردیف های حاوی سنگ از تبدیل موجک گسسته (DWT^۲) و الگوریتم ژنتیک (GA^۳) استفاده شده است. سپس به کمک یک شبکه عصبی مصنوعی عمیق با معماری DeepLab v3+ چوب های جداکننده ی Run ها شناسایی شده و بر اساس آنها در هر تصویر Run ها از یکدیگر تفکیک می شوند. در مرحله ی تشخیص Run ها از یک شبکه عصبی کانولوشنی با معماری GoogleNet به منظور حذف ردیف های خالی از سنگ استفاده شده است. مجدداً از یک DeepLab v3+ دیگر برای جداسازی تکه سنگ های بزرگتر از ۱۰ سانتیمتر در هر Run استفاده شده و در نهایت با اندازه گیری طول تکه سنگ های جداسازی شده مقدار RQD مشخص می شود. نتایج (برای ۳۰٪ از داده های تست) نشان می دهد که روش پیشنهادی در مجموع حدود ۷۷٫۸٪ دقت دارد.

۱- یافتن ROI و جداسازی ردیف ها

در این مسئله تنها سنگ های موجود در ۵ ردیف جعبه حائز اهمیت هستند و مابقی اطلاعات تصویر از جمله درب جعبه اضافی هستند. به همین منظور لازم است که برای اندازه گیری دقیق تر، بر روی ناحیه ی اصلی متمرکز شویم. همچنین برای مشخص کردن Run ها ترجیح داده شده که ردیف ها به صورت جداگانه بررسی شوند. از این رو ابتدا ۴۰٪ بالای تصویر کاملاً حذف می شود و سپس بر روی ۶۰٪ باقیمانده تبدیل موجک گسسته (DWT) اعمال می شود. این تبدیل قادر است لبه های عمودی، افقی و سطری را در تصاویر جداسازی کند. درواقع DWT با محاسبه ی نرخ تغییرات رنگ نسبت به مکان (سطری، ستونی یا قطری) به ازای هر تصویر یک مؤلفه ی فرکانس پایین (تقریب^۴) و سه مؤلفه ی فرکانس بالا (جزییات^۵) ارائه می دهد که البته در این مسئله، تنها لبه های افقی برای تفکیک ردیف های جعبه موردنظر ماست. شکل ۱ مثالی از اعمال DWT بر روی یک تصویر نمونه را نمایش می دهد. همانطور که دیده می شود، عمده ی خطوط جداکننده ی ردیف ها به خوبی نمایان شده اند.



شکل ۱ مثالی از اعمال DWT برای یافتن لبه های افقی

برای یافتن سطرهای جداکننده باید شماره ی سطرهایی که حاوی خطوط سفید هستند را بیابیم. برای یافتن خطوط مقدار تمام پیکسل های هر سطر را محاسبه می کنیم و به ازای هر سطر یک عدد به دست خواهد آمد که نشان می دهد در آن سطر چند پیکسل سفید وجود دارد. طبعاً سطرهایی که بیشترین پیکسل های سفید را دارا هستند همان خطوط جداکننده ی ردیف های جعبه می باشند. اما به دلیل کج بودن برخی از عکس ها، یافتن خطوط

^۱ Region of Interest

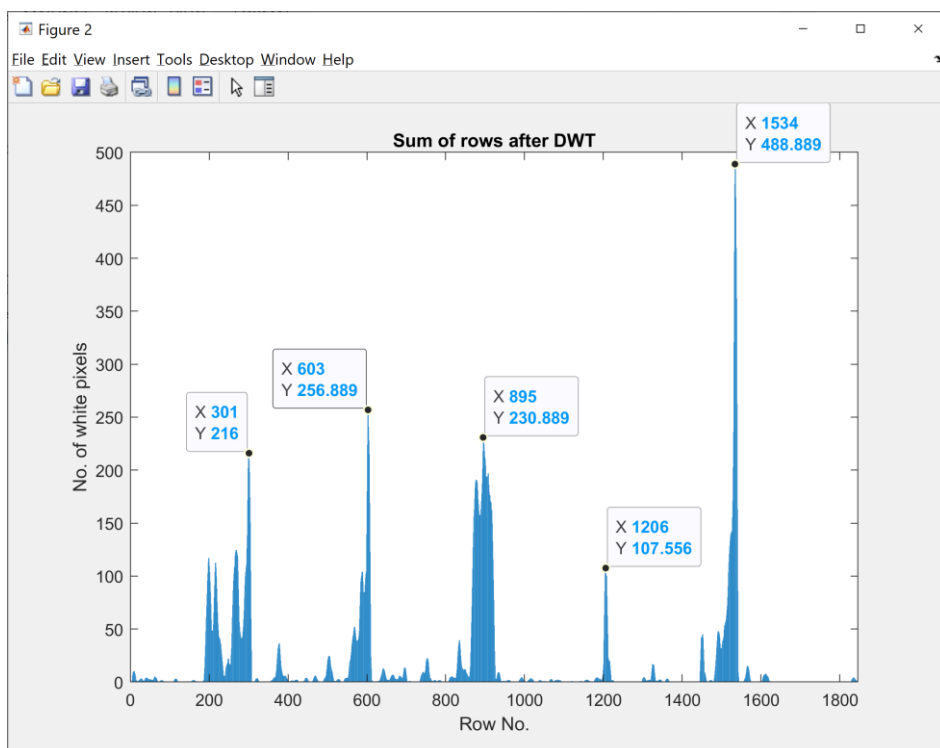
^۲ Discrete Wavelet Transform

^۳ Genetic Algorithm

^۴ Approximation

^۵ Details

چندان هم آسان نیست. نمودار شکل ۲، مجموع پیکسل‌های سفید هر سطر را برای شکل ۱ نشان می‌دهد. پیک‌هایی که در شکل مشخص شده‌اند حاوی آدرس سطری از تصویری هستند که می‌توانند ردیف‌های جعبه را از هم تفکیک کنند. درواقع آدرسِ چوب‌های جداکننده‌ی ردیف‌ها هستند.



شکل ۲ نمودار مجموع سطرها بعد از DWT

مشکلی که وجود دارد این است که پیک‌ها منحصر به فرد نیستند و هرکدام همسایگانی دارند که به بزرگی خود آنها هستند. اما می‌دانیم که تقریباً فاصله‌ی مرزهای ردیف‌ها برابر است. از این رو با حل یک مسئله‌ی بهینه‌سازی، ۵ نقطه را برای تعیین آدرس مرز ردیف‌ها تنظیم می‌کنیم. همانطور که گفته شد برای حل این مسئله‌ی بهینه‌سازی از الگوریتم ژنتیک ($GA()$) استفاده شده است. مسئله‌ی بهینه‌سازی را می‌توان به صورت زیر تعریف کرد:

$$\underset{r_1, r_2, r_3, r_4, r_5}{\text{maximize}} f(r_1, r_2, r_3, r_4, r_5) = \frac{(S_1 * S_2 * S_3)}{10 + stdev(D)} \quad (1)$$

که r_1 تا r_5 شماره سطری است که باید بیابیم و $stdev(D)$ انحراف معیار فاصله‌ی سطرها از یکدیگر است. از آنجایی که می‌دانیم فاصله‌ی سطرها از یکدیگر برابر است، در حالت ایده‌آل انحراف معیار باید صفر باشد. از این رو چون GA تلاش می‌کند رابطه‌ی ۱ را بیشینه کند، خود به خود انحراف معیار به سمت صفر حرکت کرده و تضمین می‌شود که شماره سطری‌های نهایی تقریباً فاصله‌های مساوی دارند. مقادیر S_1 تا S_3 نیز به صورت زیر تعریف می‌شوند:

$$S_1 = \sum_{i=1}^5 d_i \quad (2)$$

که d_i فاصله‌ی مرز i تا مرز $i+1$ است. لازم به توضیح است که انتهای تصویر به عنوان مرز نهایی در نظر گرفته می‌شود.

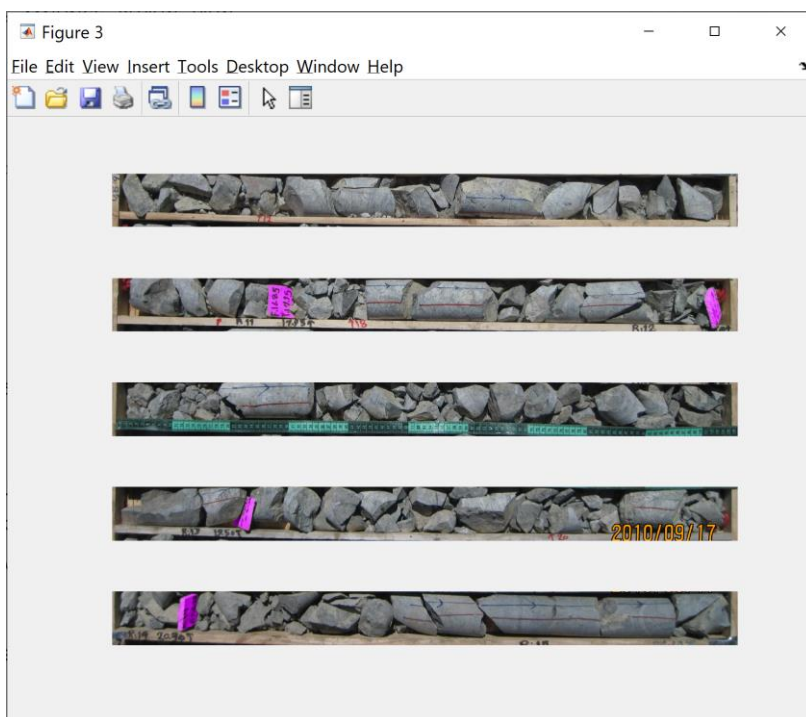
$$S_2 = \sum_{i=1}^5 \sum_{j=i-5}^{i+5} S_j \quad (3)$$

که S_j مجموع پیکسل‌های سفید سطر j بعد از DWT است. مقدار S_2 درواقع مجموع پیکسل‌های سفید سطری‌های تعیین‌شده را با ضخامت ۱۰ پیکسل (۵ پیکسل قبل و ۵ پیکسل بعد) محاسبه می‌کند. این عملیات به خاطر این است که معمولاً خطوط به دست آمده مقدار کج هستند.

$$S_3 = \sum_{j=1}^5 S_j \quad (4)$$

مقدار S_3 مجموع پیکسل‌های سفید سطرهای انتخابی را محاسبه می‌کند. طبعاً اگر نقاط در پیک‌ها افتاده باشند، مقدار S_3 باید به اندازه‌ی کافی بزرگ باشد. درمجموع GA با بیشینه‌سازی رابطه‌ی ۱ تضمین می‌کند که شماره سطرهای معرفی‌شده هم از یکدیگر فاصله‌ی یکسان داشته باشند ($\text{stdev}(D)$)، هم فاصله‌ها به اندازه‌ی کافی بزرگ باشند (S_1)، هم بر روی پیک‌ها قرار گرفته باشند (S_3)، هم اینکه همسایه‌های بزرگی داشته باشند (S_2)^۶.

با یافتن شماره سطرهای بهینه می‌توان به سادگی از هر تصویر ورودی ۵ تصویر مجزا به دست آورد که هر کدام حاوی یکی از ردیف‌های جعبه است. شکل ۳ حاصل یک اجرای نمونه را (برای تصویر شکل ۱) نمایش می‌دهد.



شکل ۳ مثالی از عملکرد DWT و GA در جداسازی ردیف‌های جعبه

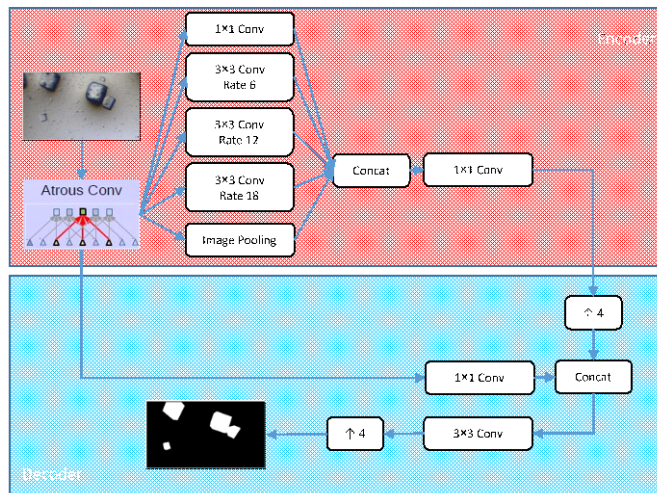
۲- تبدیل ردیف به Run با کمک DeepLab v3+ و GoogleNet

درکل رویکرد اتخاذ شده برای حل مسئله، جداسازی معنایی^۷ می‌باشد. از این رو هم برای یافتن تکه چوب‌های بنفش و هم تکه سنگ‌های بزرگتر از ۱۰ سانتیمتر از شبکه‌های کانولوشنی انکدر-دیکدر^۸ استفاده شده است. یکی از موفق‌ترین معماری‌های موجود برای جداسازی معنایی، معماری DeepLab v3+ است. این معماری در شکل ۴ قابل مشاهده است.

^۶ با توجه به محدودیت تعداد صفحات، امکان شرح بیشتر الگوریتم ژنتیک وجود ندارد. در صورت لزوم و در صورت برنده شدن، در ارائه‌ی حضوری اطلاعات بیشتری ارائه خواهد شد.

^۷ Semantic Segmentation

^۸ Encoder-Decoder Convolutional Neural Networks



شکل ۴ معماری DeepLab v3+

این شبکه یک تصویر را در ورودی دریافت کرده و پس از گذراندن تصویر از لایه‌های مختلف کانولوشنی، به ویژه لایه‌های کانولوشن Atrous، در نهایت یک تصویر در خروجی با همان ابعاد تصویر ورودی تولید می‌کند که هر پیکسل آن به یکی از کلاس‌های مدنظر ما طبقه‌بندی شده است. برای یافتن تکه‌های چوب ما هر پیکسل را به یکی از دو کلاس پس‌زمینه (bg) و چوب (wood) اختصاص می‌دهیم.

طبعاً برای آموزش شبکه نیاز به داده‌ی آموزش داریم. از این رو به صورت دستی ۲۲ تصویر از تصاویر موجود برچسب‌گذاری شده‌اند. لازم به ذکر است که از برچسب‌گذاری‌های ارائه شده در فایل label استفاده نشده. برای افزایش تعداد داده‌ها از تکنیک‌های بسط داده^۹ مانند چرخش ۱۸۰ درجه، چرخش‌های آینه‌ای عمودی و افقی استفاده شده که در نهایت ۱۳۲ تصویر برای آموزش فراهم کرده است. شبکه، پس از آموزش Woodnet نام‌گذاری شده است. شکل ۵ نمونه‌ای از جداسازی تکه‌های چوب را توسط Woodnet نمایش می‌دهد.



شکل ۵ جداسازی چوب توسط Woodnet

گاهی ممکن است برخی نقاط اضافی نیز توسط Woodnet به اشتباه چوب تشخیص داده شوند. به همین دلیل از یک فیلتر میانه برای حذف چنین نقطه‌هایی استفاده شده است تا مطمئن شویم Run‌ها درست به دست می‌آیند. با داشتن محل تکه چوب‌ها، از ابتدای ردیف اول شروع کرده و تا جایی که به اولین تکه چوب رسیدیم Run اول را تعریف می‌کنیم. برای Run‌های بعدی نیز به همین منوال عمل می‌کنیم تا هر ۵ ردیف به اتمام برسد. شکل ۶ نمونه‌ای از تبدیل ردیف‌ها به Run‌ها را نمایش می‌دهد.

^۹ Data Augmentation



شکل ۶ تبدیل ردیف به Run

در برخی از تصاویر، بخشی از ردیف‌های جعبه خالی است و علت احتمالاً این است که حفاری در آن طول به پایان رسیده است. برای اینکه بخش خالی از سنگ به عنوان یک Run در نظر گرفته نشود، لازم است که مدلی داشته باشیم که پر یا خالی بودن ردیف یا Run را تشخیص دهد. برای این منظور از یک رویکرد یادگیری انتقالی^{۱۰} استفاده شده است. یک شبکه‌ی GoogleNet که پیش‌تر برای طبقه‌بندی تصاویر در ۱۰۰۰ کلاس مختلف آموزش داده شده را انتخاب کرده و لایه‌ی آخر آن را با یک Fullyconnected برای دو کلاس (پر و خالی) جایگزین کرده‌ایم. سپس با تعداد از تصاویر ردیف‌های استاندارد (پر) و ردیف‌های خالی شبکه را تنظیم^{۱۱} کرده‌ایم. در بخش تعیین Run برای هر جعبه، برای آخرین Run مدل GoogleNet را صدا می‌زنیم و بررسی می‌کنیم که Run خالی نباشد. اگر خالی باشد، Run آخر از محاسبات حذف می‌شود.

۳- شناسایی تکه سنگ‌های بزرگ و محاسبه‌ی RQD

برای شناسایی سنگ‌ها نیز از DeepLab v3+ استفاده شده است. ۶۴ تصویر به صورت دستی برچسب‌گذاری شده و با تکنیک‌های بسط داده تصاویر آموزش به تعداد ۳۸۴ رسیده‌اند. پس از آموزش این شبکه را RockNet نام‌گذاری کرده‌ایم. شبکه‌ی RockNet پس از آموزش قادر است با دقت خوبی تکه سنگ‌ها را جداسازی کند. حال کافی است نسبت طول پیکسل‌های سفید (حاوی تکه‌سنگ‌های بزرگتر از ۱۰ سانتیمتر) را به طول کل Run تقسیم کنیم تا مقدار RQD محاسبه شود. با داشتن مقدار RQD مطابق با جدول ارائه شده در صورت سوال، کلاس هر Run مشخص می‌شود. شکل زیر نمونه‌ای از جداسازی و محاسبه‌ی کلاس RQD را نمایش می‌دهد.



شکل ۷ جداسازی تکه سنگ‌های بزرگ با RockNet و محاسبه‌ی RQD

پاسخ سوالات در صفحه بعد...

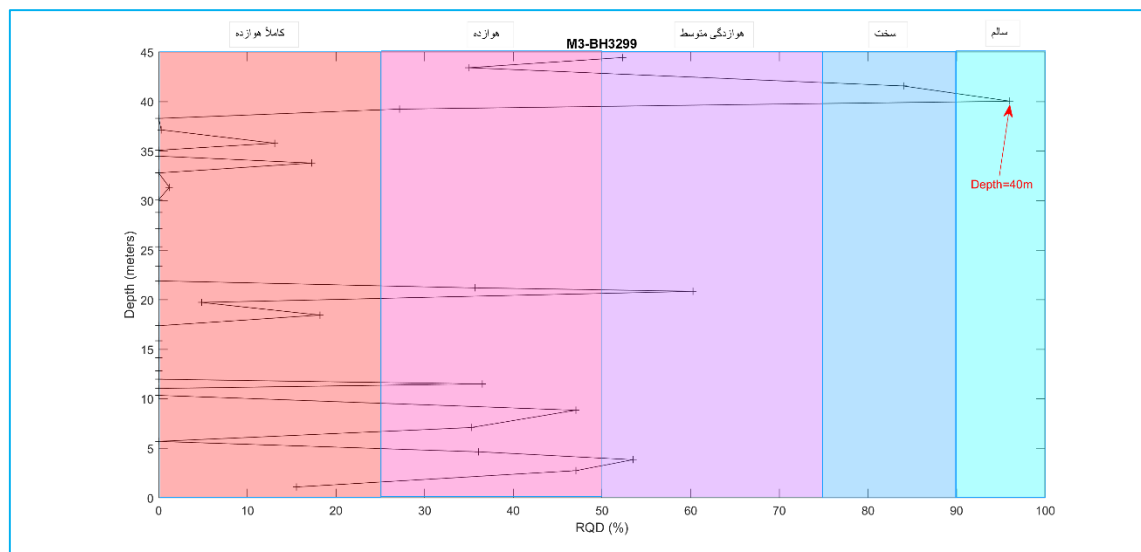
^{۱۰} Transfer Learning

^{۱۱} Fine Tuning

پاسخ سوال ۱:

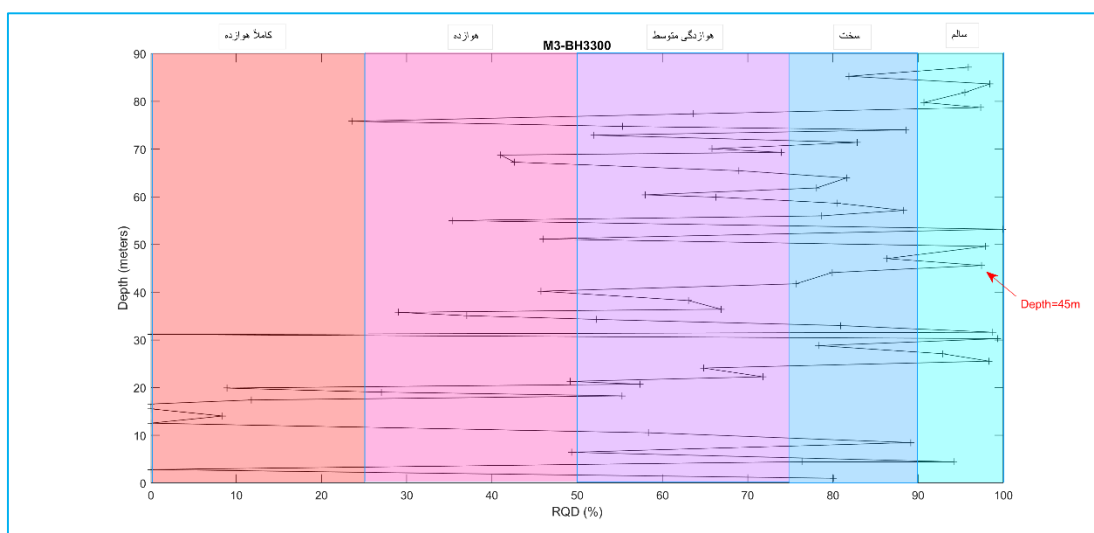
ابتدا با توجه به مدل‌های استفاده شده در سنجش کیفیت، مقدار RQD برای هر Run محاسبه می‌شود. شکل‌های ۸، ۹ و ۱۰ به ترتیب نتایج به دست آمده برای هر کدام از حفاری‌های M3-3299، M3-3300 و M3-3301 را نمایش می‌دهند. مقادیر عمق به صورت میانگین در نمودارها در نظر گرفته شده‌اند.

حفاری ۳۲۹۹ از عمق صفر تا حدود ۴۵ متر اجرا شده است و همانطور که دیده می‌شود در عمق‌های حدود ۴۰ متر سنگ‌های سالم و سخت مشاهده شده‌اند (شکل ۸).



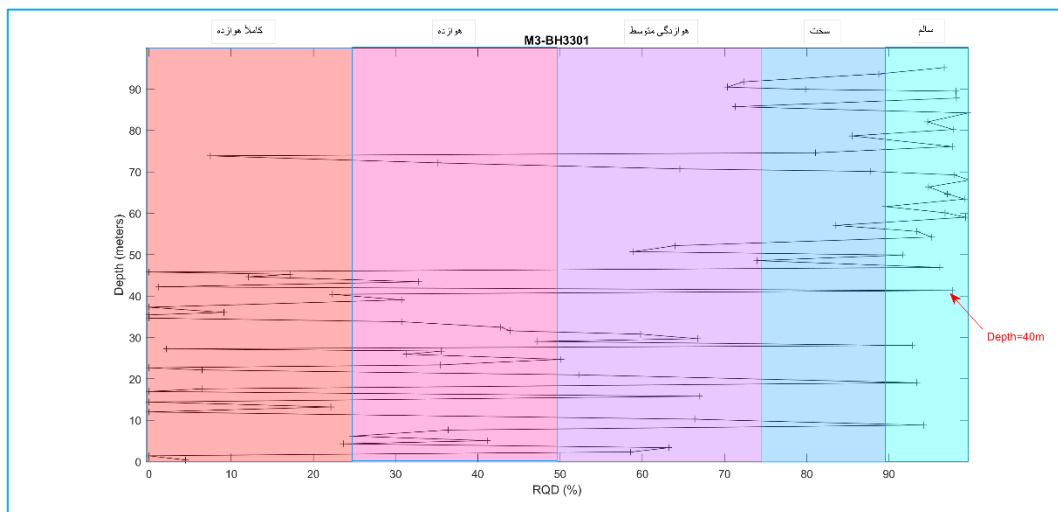
شکل ۸ مقدار RQD برای هر Run از حفاری ۳۲۹۹ در هر عمق

حفاری ۳۳۰۰ از سطح زمین شروع شده و تقریباً تا عمق ۸۷ متری ادامه داشته است. کیفیت سنگ‌های این حفاری بهتر از حفاری ۳۲۹۹ است. چرا که تا عمق ۴۵ متری سنگ‌های سالم و سخت بیشتری مشاهده شده است. همچنین دیده می‌شود که در عمق‌های ۴۰ تا ۵۰ متر، سنگ‌ها یا سخت هستند و یا سالم (شکل ۹).



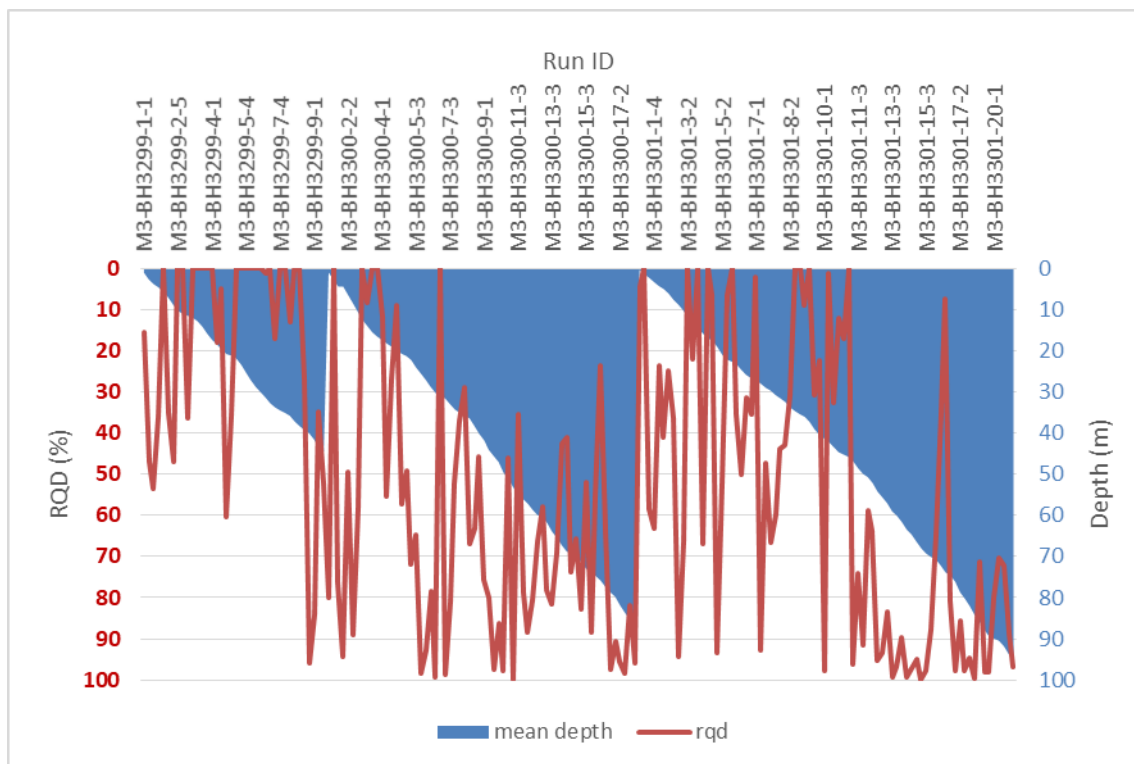
شکل ۹ مقدار RQD برای هر Run از حفاری ۳۳۰۰ در هر عمق

حفاری ۳۳۰۱ نیز تا حدود ۹۵ متری عمق زمین اجرا شده است و دیده می‌شود که از عمق ۴۵ متری به بعد کیفیت سنگ‌ها افزایش می‌یابد به طوری که در عمده‌ی Run‌ها سنگ‌های سالم و سخت دیده می‌شود. همانند دو حفاری قبل، دیده می‌شود که در حدود ۴۰ و ۴۵ متری سنگ‌های سالم (بدون هوازدگی) استخراج شده است.

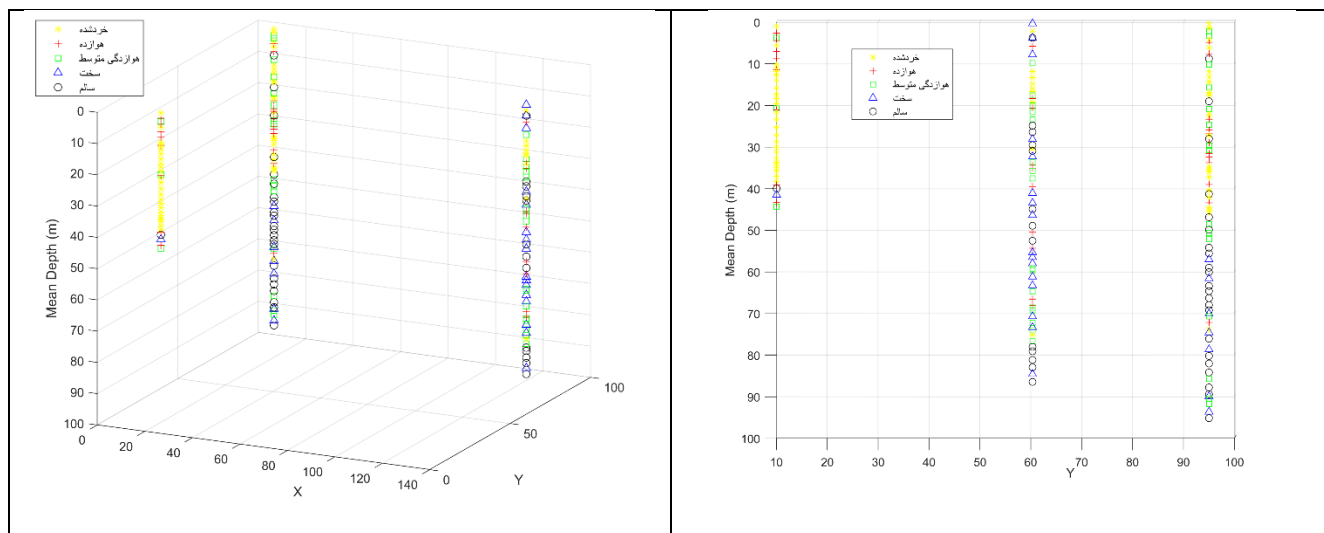


شکل ۱۰ مقدار RQD برای هر Run از حفاری ۳۳۰۱ در هر عمق

به طور تقریبی می‌توان گفت که در عمق‌های حدود ۴۰ متر در هر سه حفاری سنگ‌های سالم دیده می‌شود. شکل‌های ۱۱ و ۱۲ هر سه حفاری را در یک نمودار به همراه عمق و مقدار RQD یا کلاس آن نمایش می‌دهد.



شکل ۱۱. نتایج هر سه حفاری با هم

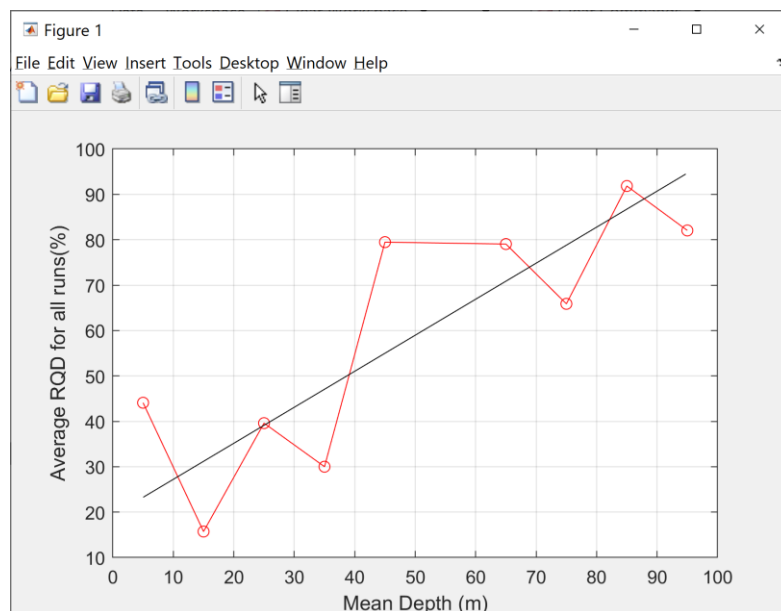


شکل ۱۲. نتایج سه حفاری در مختصات‌های داده شده

پاسخ سوال ۲:

از روی نمودارها نمی‌توان نظم خاصی مشاهده نمود یا اینکه ارتباطی بین گروه RQD و عمق یافت. اما باید در نظر گرفت که در مسئله استثنائاتی قائل شده است که ممکن است باعث ایجاد برخی خطاها شده‌اند. به عنوان مثال هر جعبه مستقل فرض شده است که در واقعیت این چنین نیست. همچنین مدل پیشنهادی در کل حدود ۲۲٪ خطا دارد. از این رو ممکن است برخی از تشخیص‌های اشتباه باعث از بین رفتن الگوی منظمی شده باشند که رابطه‌ی RQD را با عمق نشان می‌دهد.

برای بررسی دقیق‌تر در هر ۱۰ متر برای هر سه حفاری میانگین RQD محاسبه شده است. نمودار به دست آمده مطابق با شکل ۱۳ است. همانطور که دیده می‌شود، با افزایش عمق، مقدار RQD نیز افزایش یافته است. خط رگرسیون (خط سیاه رنگ)، با شیبی حدود ۰٫۸، این نتیجه‌گیری را بهتر نمایش می‌دهد.



شکل ۱۳ رابطه‌ی RQD با میانگین عمق